

ДОМАШНЕЕ ЗАДАНИЕ 3 · ТРЕТЬЯ НЕДЕЛЯ

Фреймворк, критик, голосование: что окупается

Выдано на семинаре 27.09. Дедлайн воскресенье 04.10, 23:59. Сдаётся ссылкой на репозиторий в чат курса, можно продолжать репозиторий прошлых домашних. Обязательная часть оценивается из десяти баллов, опциональная идёт в зачёт финального проекта.

Зачем это задание

Третья неделя была про то, что можно надстроить над циклом агента: фреймворк, критика, голосование, план. У каждой надстройки есть цена, и у фреймворка тоже, даже если он ничего не добавляет к качеству. Задание одно: взять своего агента, надстроить над ним то, что обещает прирост, и честно показать в центах, что окупилось, а что оказалось дорогим украшением.

Часть 1, обязательная

Шаг 1. Счётчик и базовая линия

Агент из первой или второй домашки, ваш набор вопросов, не меньше 40. Счётчик как на семинаре: один `httpx.Client` с крючком на ответ, через который ходят все исполнения, и метка конфигурации на каждом вызове. Из счётчика берутся число вызовов, токены на входе и выходе и цена из поля `usage.cost`. Первая строка таблицы это ваш голый цикл.

Шаг 2. Фреймворк и его налог

Перенесите агента на LangGraph или на smolagents: те же инструменты, тот же системный промпт, та же модель. В отчёте:

- строка таблицы для фреймворка на том же наборе;
- «пустой запрос»: сколько токенов уходит в первом же вызове на простом вопросе у вашего цикла и у фреймворка, и откуда разница. Сравните первый запрос байт в байт: на семинаре LangGraph молча потерял описания аргументов и падал вместо ответа на последнем шаге;
- одна фраза: что фреймворк сделал за вас такого, что стоит этих токенов, или почему не стоит.

Шаг 3. Два паттерна недели

Выберите два из трёх и добавьте их к лучшему из двух исполнений:

- 1. Критик с опорой.** Не «перепроверь себя», а проверка источником, инструментом или кодом. Вердикт по схеме, не больше двух попыток исправиться. Посчитайте, сколько неверных ответов критик исправил и сколько верных испортил.
- 2. Голосование и каскад.** Несколько независимых прогонов, ответ большинством, при неполном согласии задача уходит модели посильнее. Доля задач, ушедших наверх, и цена верного ответа против сильной модели на всём наборе. Согласие мерьте на коротких ответах: на семинаре агент отвечал фразами, и наверх ушло 32 вопроса из 40.
- 3. План.** Отдельный вызов пишет план, план идёт в промпт исполнителя. Или вариант с раздельным исполнением из девятой лекции. Сравните с тем же агентом без плана.

Проверка проверки

Функция, которая решает «верно или нет», часть вашей системы, и она ошибается так же тихо, как модель: на лекции 11 мы рассказали, как наша регулярка треть ответов дешёвой модели записала в неверные. Прежде чем делать выводы, прочитайте глазами десять ответов, которые проверка сочла неверными, для каждой конфигурации, где есть сомнения. Ошибаться может и эталон: на семинаре Википедия обновила число погибших с 43 до 46, и все модели «ошиблись» одинаково. В отчёте раздел «Проверка проверки»: сколько из них на самом деле верны и что вы поправили.

Шаг 4. Итог

Одна таблица на все конфигурации и одна картинка «цена вопроса против доли верных». Обязательные строки: голый цикл, фреймворк, два паттерна и сильная модель в одиночку как ориентир. Колонки как на семинаре: доля верных, вызовов на вопрос, токенов на вопрос, центов на вопрос, центов за верный ответ. Две строки выводов, как просили на восьмой лекции: что дало прирост и что оказалось дорогим украшением.

Шаг 5. Потолок на деньги

Ограничьте число вызовов модели на один вопрос кодом, а не промптом. В LangGraph для этого есть промежуточный слой `ModelCallLimitMiddleware`, в smolagents параметр `max_steps`, можно и свой счётчик. Покажите вопрос, на котором ограничение сработало, и что агент ответил после обрыва.

Что сдавать

- `README.md`: итоговая таблица, картинка, налог фреймворка на пустом запросе, счёт критика или доля эскалаций, раздел «Проверка проверки», две строки выводов;
- ноутбук или скрипты с выполненными ячейками и понятным запуском;
- `.env.example`, `requirements.txt`, ключа в истории коммитов нет.

Оценка, 10 баллов

Критерий	Баллы
Репозиторий запускается с чистого клона, ключа в истории нет	1
Счётчик HTTP и базовая линия на наборе от 40 вопросов	1
Агент на фреймворке, строка таблицы и налог на пустом запросе	2
Два паттерна недели, счёт «исправил против испортил» или доля эскалаций	3
Итоговая таблица, картинка и две строки выводов	2
Проверка проверки и потолок на деньги	1
Бонус: третий паттерн недели	+1
Бонус: остановка на подтверждение человеком перед необратимым инструментом	+1

Как и раньше, оценка не зависит от того, подтвердился тезис или нет. Результат «фреймворк втрое дороже и ничего не дал», если он честно посчитан, стоит столько же, сколько победа.

Бюджет

Прогон на сорока вопросах в пяти-шести конфигурациях на mini стоит десятки центов. Основной счёт дают голосование, потому что каждый голос это целый прогон агента, и строка с сильной моделью. Если счётчик ушёл за два доллара, проверьте, не гоняете ли вы сильную модель там, где хватило бы части набора, и не зациклился ли агент без потолка из шага 5.

Часть 2, опциональная: каркас вашего агента

Продолжение проекта для тех, у кого задача уже согласована с @artemovma.

Шаг 1. Схема агента на одной странице

ARCH.md : какие узлы у вашего агента, какие скиллы из первой домашки к ним подключены, где стоит проверка, где нужен человек, где потолок на деньги. Какой фреймворк выбран и почему, с цифрой налога на пустом запросе для ваших скиллов.

Шаг 2. Рабочий каркас

- Граф или агент на выбранном фреймворке, в котором подключены ваши четыре-пять скиллов;
- остановка на подтверждение человеком перед каждым необратимым скиллом: отправка, оплата, удаление;
- потолок на число вызовов модели и замер цены одного типового запроса счётчиком HTTP.

Сдаётся в папке `project` . Оценивается как бонус, до трёх баллов, и переносится в зачёт финального проекта.

Вопросы по заданию в чат курса. Проблемы с ключом и бюджетом: @artemovma в телеграме. Следующая неделя: несколько агентов, дебаты и протоколы MCP и A2A.